

## REPORTE DE PRÁCTICA

### IDENTIFICACIÓN DE LA PRÁCTICA

Práctica	1	Nombre de la práctica	Regresión lineal univariable
Fecha	02/10/2021	Nombre del profesor	Alma Nayeli Rodríguez Vázquez
Nombre del estudiante		Mariana Ávalos Arce	

### OBJETIVO

El objetivo de esta práctica consiste en implementar la técnica de regresión lineal univariable en Matlab/Octave y en Python.

### PROCEDIMIENTO

Realiza la implementación siguiendo estas instrucciones.

Implementa el método de regresión lineal en Matlab/Octave y en Python. Para ello, considera los siguientes requerimientos:

- Utiliza el set de datos del archivo "dataset\_RegresionLineal.txt".
- Utiliza los siguientes valores para los parámetros iniciales:  
`a0=0 a1=0 beta=0.023 iteraciones=600`
- Reporta el error  $J$  y el valor final de  $a0$  y  $a1$ . Además, reporta el valor de  $h$  para el dato de prueba  $x = 9.7687$ , cuya salida correcta es  $y = 7.5435$ .
- Comprueba tus resultados con los siguientes:  
`J=4.4869 a0=-3.5657 a1=1.1599`  
Dato de prueba  $x=9.7687$ . Salida correcta  $y=7.5435$ . Predicción  $h=7.7648$

### IMPLEMENTACIÓN EN MATLAB/OCTAVE

Agrega el código de tu implementación en Matlab/Octave en el siguiente espacio.

```
% code for linear regression using training data set file

close all % close windows
clear all % clear variables
%training data
data = load("dataset.txt")

% data is a matrix of 97 rows and 2 cols
x = data(:,1);
y = data(:,2);

figure(1)
plot(x, y, 'ok', 'MarkerFaceColor', 'y', 'MarkerSize', 5)
xlabel("x: characteristics (house area)")
ylabel("y: correct output (house price)")
title("Data Plot")
hold on
```



UNIVERSIDAD  
PANAMERICANA

# Universidad Panamericana

Campus Guadalajara

Especialidad en Ciencia de Datos

## Introducción al aprendizaje de máquina

```
% initial parameters
a0 = 0; % 1
a1 = 0; % 1
beta = 0.023; % change this
iterMax = 600; % change this

% size of training data
m = numel(x);
iter = 1;

% hypothesis: vector result called h
h = a0 + a1*x;
% if you dont plot markers, it will be plotted as line
plot(x, h, 'r');

% sum sums all vector elements
% . for element by element operation
J = (1/(2*m))*sum((h - y).^2);
conv = [];

while(iter <= iterMax)
    a0 = a0 - beta*(1/m)*sum(h - y);
    a1 = a1 - beta*(1/m)*sum((h - y).* x);
    h = a0 + a1*x;
    %plot(x, h, 'g')
    %pause(1)
    J = (1/(2*m))*sum((h - y).^2);
    conv(iter) = J; % conv[iter]
    iter = iter + 1;
end

figure(1)
plot(x, h, 'g')
figure(2)
plot(conv, 'b')
xlabel("Number of Iterations")
ylabel("Error J")
title("Convergence Plot")

input_data = 9.7687; % must be normalized as well
output_h = a0 + a1*input_data;
figure(1)
plot(input_data, output_h, 'ok', 'MarkerFaceColor', 'm', 'MarkerSize', 8)

fprintf('J = %.4f a0 = %.4f a1 = %.4f \nTest: \nx = %.4f y= 7.5435 h = %.4f \n', J, a0, a1,
input_data, output_h)
```

## IMPLEMENTACIÓN EN PYTHON

Agrega el código de tu implementación en Python en el siguiente espacio.

```
import matplotlib.pyplot as plt
import numpy as np

# example training data from file
f = open("dataset.txt", "r")
lines = f.readlines()
x = [float(line.split(',')[0]) for line in lines]
y = [float(line.split(',')[1]) for line in lines]

# example training data
#x = [9, 12, 24, 45, 10.5]
#y = [1200, 1520, 2300, 3400, 1370]

fig = plt.figure()
fig.add_subplot()
ax1 = plt.gca()

ax1.scatter(x, y, s=100, color='yellow', marker="o", linewidths=1, edgecolor='black')

a0 = 0.0
a1 = 0.0
beta = 0.023
iterMax = 600

m = len(x)
iter = 1

h = [(a0 + a1 * x_val) for x_val in x]

ax1.plot(x, h, color='r')
sums = [(h_val - y_val)**2 for h_val, y_val in zip(h, y)]
J = (1.0 / 2.0 * m) * sum(sums)
conv = [] # convergence vector

while iter <= iterMax:
    sums0 = [(h_val - y_val) for h_val, y_val in zip(h, y)]
    a0 = a0 - beta * (1.0 / m) * sum(sums0)
    sums1 = [(h_val - y_val) * x_val for h_val, y_val, x_val in zip(h, y, x)]
    a1 = a1 - beta * (1.0 / m) * sum(sums1)
    h = [(a0 + a1 * x_val) for x_val in x]

    sums = [(h_val - y_val)**2 for h_val, y_val in zip(h, y)]
    J = (1.0 / 2.0 * m) * sum(sums)
    conv.append(J)
    iter += 1

ax1.plot(x, h, color='g')
ax1.set_title('Univariate Linear Regression')
ax1.set_ylabel("Price")
ax1.set_xlabel("Area")

fig2 = plt.figure()
fig2.add_subplot()
ax2 = plt.gca()

# for convergence plot
```



UNIVERSIDAD  
PANAMERICANA

# Universidad Panamericana

Campus Guadalajara

Especialidad en Ciencia de Datos

## Introducción al aprendizaje de máquina

```
min = 0.0
max = iterMax * 1.0
xs = list(np.arange(min, max, max / len(conv)))
ax2.plot(xs, conv, color='orange')
ax2.set_title('Error Convergence')
ax2.set_ylabel("Error (J)")
ax2.set_xlabel("Iterations")



# plot test data and output
input_data = 9.7687
output_h = a0 + a1 * input_data
ax1.scatter([input_data], [output_h], marker='o', color='magenta', s=100, linewidths=1, zorder=100,
edgecolor='black')

plt.show()

print(f"\n\n J = {J} a0 = {a0} a1 = {a1} \n Test:\n x = {input_data} y = 7.5435 h = {output_h}\n")
```

### RESULTADOS EN MATLAB/OCTAVE

Agrega en los espacios indicados las imágenes de los resultados obtenidos en Matlab/Octave.



Gráfica de convergencia generada en Matlab

Gráfica del resultado final en Matlab  
(datos de entrenamiento, línea inicial y final)

```
J = 4.4868 a0 = -3.5671 a1 = 1.1600
Test:
x = 9.7687 y= 7.5435 h = 7.7647
>> |
```

Imagen de los resultados de la ventana de comandos de Matlab en la que se despliegan los valores de  $J$ ,  $a_0$ ,  $a_1$ , el dato de prueba  $x$  con la salida correcta  $y$  y su predicción  $h$



UNIVERSIDAD  
PANAMERICANA

# Universidad Panamericana

Campus Guadalajara

Especialidad en Ciencia de Datos

## Introducción al aprendizaje de máquina

### RESULTADOS EN PYTHON

Agrega en el siguiente espacio la imagen de los resultados obtenidos en Python en el que se desplieguen los valores de  $J$ ,  $a_0$ ,  $a_1$ , el dato de prueba  $x$  con la salida correcta  $y$  y su predicción  $h$ .

```
J = 42216.37465806865 a0 = -3.5670775888831416 a1 = 1.1600118333815634
Test:
x = 9.7687 y = 7.5435 h = 7.764730007871338
```

### CONCLUSIONES

Escribe tus observaciones y conclusiones.

Resultó muy palpable la diferencia entre un lenguaje y otro, sobre todo respecto a la manipulación de vectores. En Matlab resulta más compacto el código que tenga que ver con operaciones vectoriales, como lo es la Regresión Lineal de una variable, en comparación con Python, a pesar de ser un lenguaje ya muy simple. Además, la propagación del error podría reducirse con ayuda de la gráfica de los valores de  $J$  comparado con el número de iteraciones, ya que brinda una idea de más o menos cuándo el error se vuelve constante a lo largo del tiempo.